

Хакатон МИФИ

Сжатие погодных данных: автокодировщики над полями ERA5 с ограниченной выборкой на обучение

Концепция и техническое задание

24 июля 2026 г.

Аннотация

Цель хакатона — исследовать, можно ли на одной GPU и небольшом наборе глобальных метеорологических кадров обучить компактное представление полного состояния нижней атмосферы. Единый вход содержит восемь приземных полей и температуру, ветер, геопотенциал и влажность на уровнях 1000/925/850/700 hPa, всего 28 каналов. Представление должно обеспечивать 32–64-кратное сжатие, качественное восстановление и сохранять информацию, полезную для простой задачи прогноза. Главный результат — минимальный объём уникальных обучающих данных, при котором модель проходит заранее зафиксированные статистические критерии.

1 Мотивация

Глобальные реанализы, такие как ERA5 [1], содержат согласованные во времени поля атмосферы и поверхности, но требуют больших объёмов хранения и вычислений. Современные погодные foundation-модели [4, 5] обычно обучаются на многолетних архивах и крупных ускорительных кластерах. Это затрудняет воспроизводимые исследования для небольших команд.

Хакатон ставит обратный вопрос: *какой минимальный набор погодных состояний достаточен, чтобы на ограниченных ресурсах выучить полезное представление?* Реконструкция рассматривается не как самоцель. Качественное представление должно одновременно:

- компактно кодировать многоканальные погодные поля;
- сохранять крупномасштабную динамику и мелкомасштабные структуры;
- переноситься на простую downstream-задачу при замороженном энкодере;
- воспроизводиться при фиксированном объёме данных и compute-бюджете.

В качестве внешнего ориентира используется VAEformer — нейросетевой кодек, на основе которого создан набор CRA5 [3]. При этом задача хакатона не состоит в достижении заявленной для CRA5 экстремальной компрессии: участники исследуют более умеренный диапазон 32–64×, но при существенно меньших ресурсах и с явной оценкой data efficiency.

2 Единая конфигурация данных

Направления не разделяются на surface- и upper-air-треки. Каждый участник обучает одну модель на одном и том же 28-канальном состоянии атмосферы. Эксперименты проводятся на сетках 0.5° и 0.25° с тем же порядком каналов и временным шагом 6 часов.

2.1 Приземные поля: 8 каналов

Код	Имя в WeatherBench 2	Физический смысл	Единицы
t2m	2m_temperature	температура воздуха на высоте 2 м	К
mslp	mean_sea_level_pressure	давление, приведённое к среднему уровню моря	Па
u10	10m_u_component_of_wind	зональная компонента ветра на высоте 10 м	m s^{-1}
v10	10m_v_component_of_wind	меридиональная компонента ветра на высоте 10 м	m s^{-1}
tp6h	total_precipitation_6hr	накопленные осадки за предыдущие 6 часов	м
sst	sea_surface_temperature	температура поверхности моря	К
tcwv	total_column_water_vapour	полное содержание водяного пара в колонке	kg m^{-2}
tcc	total_cloud_cover	доля ячейки, покрытая облаками	0–1

Таблица 1: Приземная часть единого входного тензора.

u10 и v10 оцениваются отдельно; скорость $\sqrt{u10^2 + v10^2}$ публикуется как диагностическая метрика. Для mslp физический RMSE дополнительно приводится в hPa, для tp6h — в mm/6h. SST восстанавливается и оценивается только по океанской маске; значения над сушей после нормализации заполняются нулём.

2.2 Атмосферные поля: 20 каналов

Для каждой из пяти переменных берутся ровно четыре изобарических уровня:

$$\mathcal{P} = \{1000, 925, 850, 700\} \text{ hPa.}$$

Код	Имя в WeatherBench 2	Физический смысл	Единицы	Каналов
T	temperature	температура воздуха на каждом уровне	К	4
U	u_component_of_wind	зональная компонента ветра	m s^{-1}	4
V	v_component_of_wind	меридиональная компонента ветра	m s^{-1}	4
Z	geopotential	геопотенциал; для отчёта также Z/g	$\text{m}^2 \text{s}^{-2}$	4
Q	specific_humidity	удельная влажность	kg kg^{-1}	4

Таблица 2: Атмосферная часть: пять переменных на уровнях 1000/925/850/700 hPa.

Зафиксированный порядок каналов:

$$[t2m, mslp, u10, v10, tp6h, sst, tcwv, tcc, \\ T_{1000}, T_{925}, T_{850}, T_{700}, U_{1000}, \dots, U_{700}, V_{1000}, \dots, V_{700}, \\ Z_{1000}, \dots, Z_{700}, Q_{1000}, \dots, Q_{700}].$$

Статические land_sea_mask, орография и координатные признаки $\sin \varphi, \cos \varphi$ могут подаваться как известное encoder/decoder conditioning. Они не являются восстанавливаемыми погодными каналами и не включаются в числитель compression ratio.

2.3 Где именно брать данные

Рекомендуемый источник — готовый ERA5 Zarr из WeatherBench 2 [2]. Он уже приведён к регулярной сетке 0.25° , содержит шестичасовые кадры, производную total_precipitation_6hr и все четыре требуемых pressure levels:

```
gs://weatherbench2/datasets/era5/
1959-2023_01_10-wb13-6h-1440x721_with_derived_variables.zarr
```

Описание структуры и список доступных массивов находятся в [официальном WeatherBench 2 Data Guide](#). Доступ анонимный; достаточно `xarray`, `zarr`, `dask` и `gcsfs`. После открытия нужно выбрать перечисленные выше переменные, выполнить `sel (level=[1000, 925, 850, 700])` и ограничить временной диапазон.

Сетка 0.25° берётся непосредственно из `Zarr` (721×1440 , включая полюса). Сетка 0.5° создаётся из неё один раз `first-order conservative remapping` на общий `cell-centred grid` 360×720 : широты от -89.75° до 89.75° , долготы от 0° до 359.5° . Для воспроизводимости используются единые веса ремаппинга и готовый локальный `Zarr`.

Альтернативный официальный источник — Copernicus CDS:

- [reanalysis-era5-single-levels](#) для восьми приземных полей [8];
- [reanalysis-era5-pressure-levels](#) для T, U, V, Z, Q на 1000/925/850/700 hPa [9].

В CDS запрашиваются `product_type=reanalysis`, времена 00/06/12/18 UTC и `grid 0.25/0.25` или `0.5/0.5`. При этом `tp6h` нужно корректно получить из накопленных осадков; поэтому для хакатона предпочтителен готовый `derived`-канал WeatherBench 2.

2.4 Временные разбиения и локальная подготовка

Предлагается использовать 2014–2019 годы как обучающий пул, 2020 год для `validation` и выбора `checkpoint`, 2021 год только для финального теста. Статистики нормализации и диапазоны PSNR нельзя оценивать по тестовому году.

Для эксперимента формируются сезонно сбалансированные вложенные наборы:

$$N \in \{128, 256, 512, 1024, 2048, 4096, 8192\}$$

уникальных шестичасовых глобальных кадров. Каждый следующий набор содержит предыдущий. Число случайных `patches` не считается размером датасета: участник отдельно сообщает количество уникальных времён, `optimizer steps` и суммарно просмотренных примеров.

Выбранные `timestamps` и 28 каналов сохраняются в два локальных набора:

- `era5_28ch_0p25_6h.zarr`;
- `era5_28ch_0p5_6h.zarr`.

Для каждого поля публикуются `mean/std`, океанская маска, единицы, порядок каналов, SHA256 манифеста и индексы `train/validation/test`. Так участникам не требуется скачивать весь ERA5.

3 Ограничение ресурсов

Единая задача должна быть доступна небольшой исследовательской команде:

- не более одной GPU и 24 GB peak VRAM;
- не более 20 миллионов обучаемых параметров;
- не более 50 000 шагов оптимизации;
- не более 48 GPU-часов в фиксированном эталонном окружении;
- запрещено дополнительное предобучение на неуказанных погодных архивах.

Обучение на 0.25° разрешается `patch-based`, но финальный `encoder` и `decoder` должны обрабатывать всю глобальную сетку тайлами без швов. Потребление ресурсов измеряется в одном зафиксированном окружении. Внешнее погодное `pretraining` должно быть явно заявлено и не участвует в оценке `data efficiency`.

4 Задачи

4.1 Задача 1: компактное восстановление

Участник обучает автоэнкодер с квантованным bottleneck. Официальная степень сжатия считается по фактическому сериализованному потоку:

$$CR = \frac{32 T C H W}{8B},$$

где B — полный размер bitstream в байтах, включая латенты, side information и заголовки. Должно выполняться точное равенство квантованных символов после encode—decode. Если entropy coding отсутствует, результат обозначается как latent reduction и не участвует в codec-зачёте. Такой протокол соответствует общепринятой rate-distortion постановке обучаемых кодеков [7].

4.2 Задача 2: проверка представления

После обучения энкодер и декодер замораживаются. Небольшая latent-модель не более 2 миллионов параметров обучается по текущему состоянию предсказывать латентное состояние через 6 часов, после чего результат декодируется в погодные поля. Для probe используются ровно 1024 обучающие пары и не более 5000 шагов. Эта задача проверяет, содержит ли bottleneck переносимую информацию о динамике, а не только позволяет воспроизвести вход.

Дополнительный masked-reconstruction probe может использовать подходы, аналогичные погодным masked autoencoders [6].

5 Явные метрики и критерии

Для поля f используется latitude-weighted RMSE:

$$\text{RMSE}_f = \sqrt{\frac{\sum_{t,i,j} \cos \varphi_i (\hat{x}_{tijf} - x_{tijf})^2}{\sum_{t,i,j} \cos \varphi_i}}, \quad \text{NRMSE}_f = \frac{\text{RMSE}_f}{\sigma_{f,\text{train}}}.$$

Surface score — равновзвешенное среднее NRMSE по восьми приземным полям. Pressure score — равновзвешенное среднее по 20 парам “переменная—уровень”. Чтобы высотные каналы не доминировали только из-за их количества, общий score определяется как

$$S_{\text{all}} = \frac{1}{2} S_{\text{surface}} + \frac{1}{2} S_{\text{pressure}}.$$

Дополнительно публикуются физический RMSE, PSNR с диапазонами 0.5–99.5 перцентилей, сферические энергетические спектры и метрики экстремальных осадков.

Фраза “не хуже VAEformer” заменяется проверяемым критерием не меньшей эффективности. Для каждого тестового времени вычисляется

$$\Delta = 100 \left(\frac{\text{NRMSE}_{\text{model}}}{\text{NRMSE}_{\text{reference}}} - 1 \right).$$

95% доверительный интервал оценивается парным block bootstrap с семидневными блоками и 2000 повторениями.

Для latent-прогноза публикуется относительное улучшение NRMSE по сравнению с персистентностью и с тем же probe поверх признаков референса. Метрики WeatherBench 2 используются там, где их определения применимы к шестичасовому прогнозу.

Критерий допуска	32×	64×
Верхняя граница 95% CI для общего NRMSE	$\leq +3\%$	$\leq +7\%$
Верхняя граница 95% CI для surface/pressure score	$\leq +5\%$	$\leq +8\%$
Верхняя граница для отдельного критического поля	$\leq +7\%$	$\leq +10\%$
Нижняя граница разности PSNR	≥ -0.25 dB	≥ -0.5 dB
Ухудшение spectral error	$\leq 5\%$	$\leq 10\%$
Фактический compression ratio и exact roundtrip	обязательны	обязательны

Таблица 3: Критерии non-inferiority относительно VAEformer.

6 Формат сдачи и ожидаемый результат

Команда предоставляет код, container, checkpoint, encoder/decoder, bitstream, манифест временных индексов, JSON с метриками, затраты ресурсов и графики качество–данные и качество–битрейт. К постановке прилагаются единый evaluator и baseline outputs на общих полях.

Итогом хакатона должна стать открытая эмпирическая карта того, сколько погодных данных необходимо для обучения 28-канального компактного представления нижней атмосферы на одной GPU. Поверхностные и высотные поля всегда обучаются совместно; результаты на 0.5° и 0.25° показывают, как меняется минимальный объём данных при росте пространственного разрешения.

Список литературы

- [1] Hersbach, H. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146, 1999–2049, 2020. [doi:10.1002/qj.3803](https://doi.org/10.1002/qj.3803).
- [2] Rasp, S. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 16, 2024. [doi:10.1029/2023MS004019](https://doi.org/10.1029/2023MS004019); [code and data](#).
- [3] Han, T., Chen, Z., Guo, S., Xu, W., Bai, L. CRA5: Extreme Compression of ERA5 for Portable Global Climate and Weather Research via an Efficient Variational Transformer. arXiv:2405.03376, 2024. [paper](#); [code and data](#).
- [4] Nguyen, T., Brandstetter, J., Kapoor, A., Gupta, J. K., Grover, A. ClimaX: A foundation model for weather and climate. arXiv:2301.10343, 2023. [paper](#).
- [5] Schmude, J. et al. Prithvi WxC: Foundation Model for Weather and Climate. arXiv:2409.13598, 2024. [paper](#).
- [6] Man, X., Zhang, C., Feng, J., Li, C., Shao, J. W-MAE: Pre-trained weather model with masked autoencoder for multi-variable weather forecasting. arXiv:2304.08754, 2023. [paper](#).
- [7] Ballé, J., Minnen, D., Singh, S., Hwang, S. J., Johnston, N. Variational Image Compression with a Scale Hyperprior. *International Conference on Learning Representations*, 2018. [paper](#).
- [8] Copernicus Climate Change Service. ERA5 hourly data on single levels from 1940 to present. Climate Data Store. [doi:10.24381/cds.adbb2d47](https://doi.org/10.24381/cds.adbb2d47).
- [9] Copernicus Climate Change Service. ERA5 hourly data on pressure levels from 1940 to present. Climate Data Store. [doi:10.24381/cds.bd0915c6](https://doi.org/10.24381/cds.bd0915c6).